



Large Deviations of Convex Hulls of Random Walks and Other Stochastic Models

Hendrik Schawe

19.03.2019

Large Deviations von

- ▶ Konvexe Hüllen von Random Walks
- ▶ Grundzustands-Energie eines Random-Energy Modells
- ▶ Zweifachzusammenhangs-Komponente von Zufallsgraphen
- ▶ Längste aufsteigende Teilfolge von Zufälligen Permutationen und Random Walks

untersucht mittels Markov-Chain-Monte-Carlo Simulationen

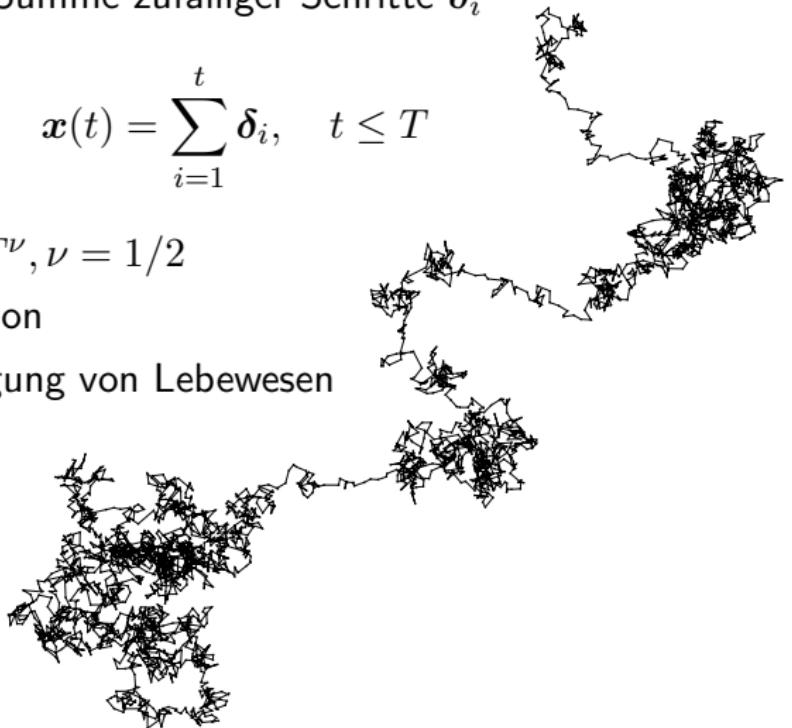


Was sind Random-Walks?

- Position $x(t)$ ist Summe zufälliger Schritte δ_i

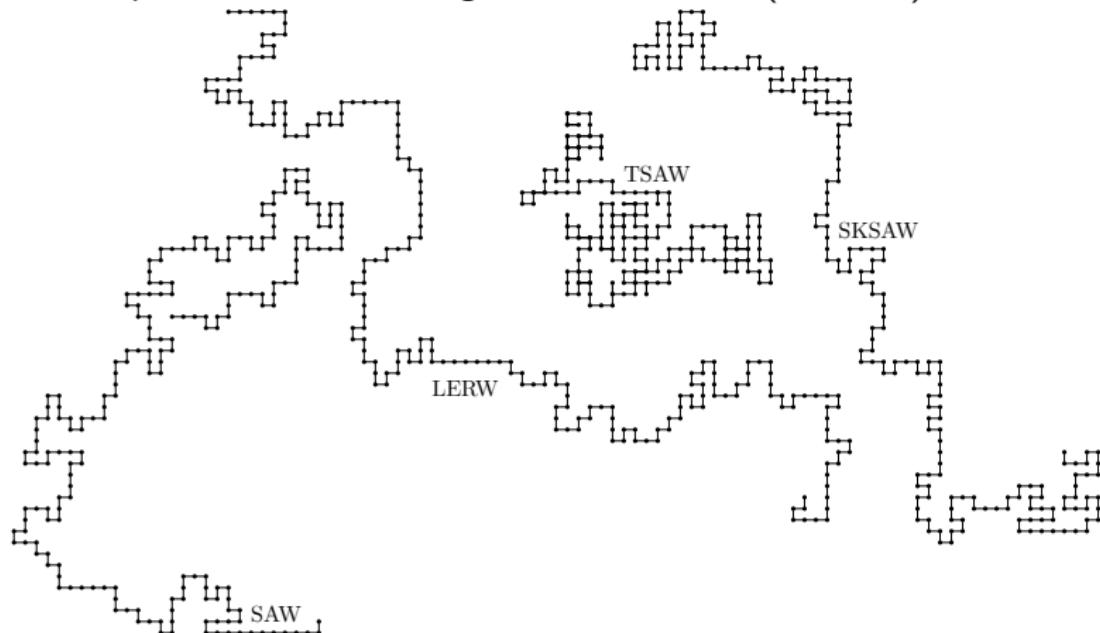
$$x(t) = \sum_{i=1}^t \delta_i, \quad t \leq T$$

- skaliert wie $r \propto T^\nu, \nu = 1/2$
- Modell für Diffusion
- Modell für Bewegung von Lebewesen



Was sind Self-Avoiding-Random-Walks?

- Zusatzregeln zur Modellierung komplexerer Objekte
- Polymere: Zwei Teile können nicht das selbe Volumen belegen
- Wachstumsprozesse
- superdiffusiv in niedrigen Dimensionen ($\nu > 0.5$)



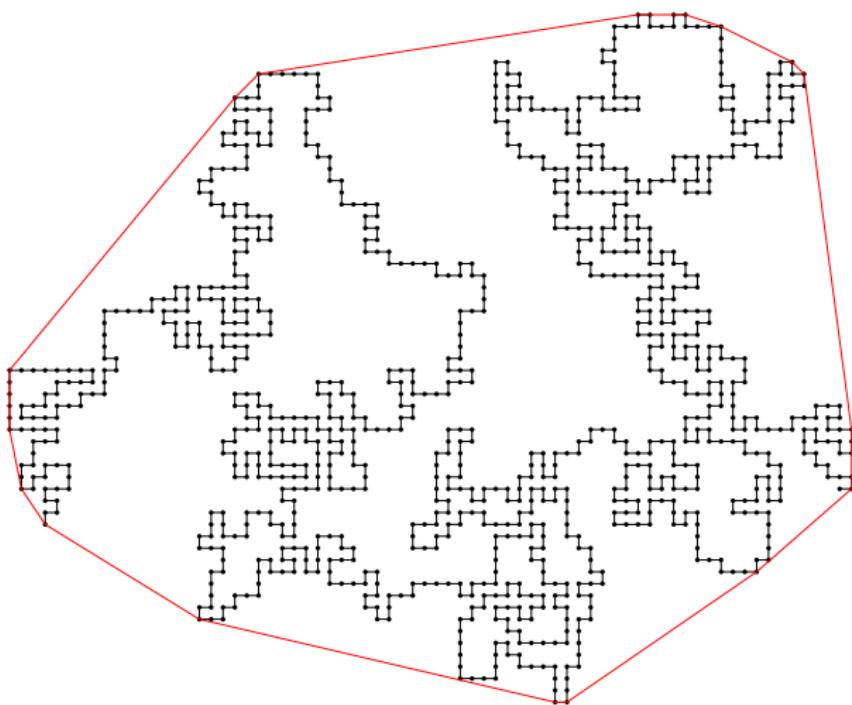
Smart-Kinetic-Self-Avoiding-Walk und konvexe Hülle



[animation]



Smart-Kinetic-Self-Avoiding-Walk und konvexe Hülle

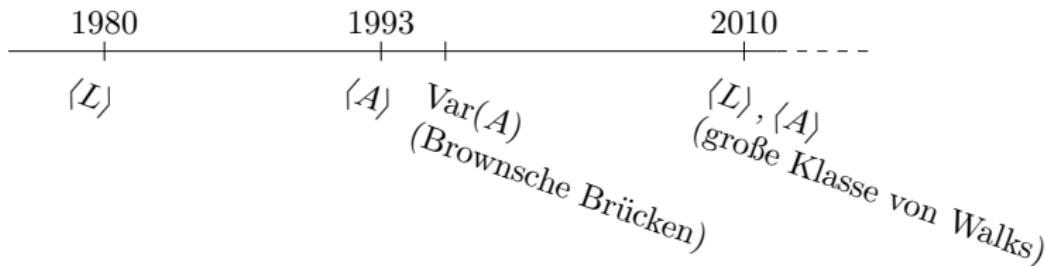


[animation]



Kovexe Hüllen von Random Walks

- ▶ Revier von Lebewesen Randon-Furling, Majumdar, Comtet (2009)
- ▶ Krankheitsausbreitung Dumonteil, Majumdar, Rosso, Zoia (2013)
- ▶ grundlegendes Interesse seit ~ 40 Jahren

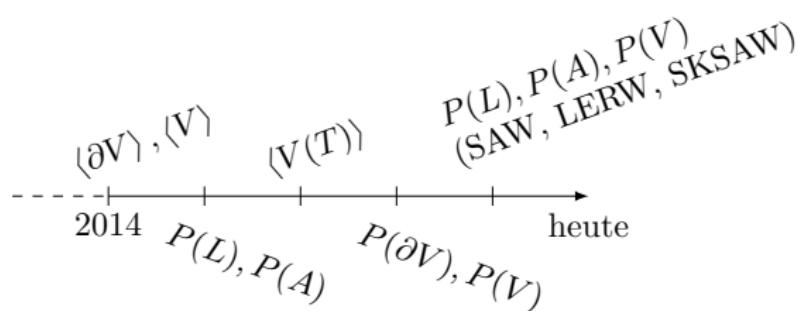


Letac, Takács (1980), Letac (1993), Goldman (1996), Majumdar, Comtet, Randon-Furling (2010),
Eldan (2014), Claussen, Hartmann, Majumdar (2015), Kabluchko, Zaporozhets (2016),
Schawe, Hartmann, Majumdar (2017), Schawe, Hartmann, Majumdar (2018)



Kovexe Hüllen von Random Walks

- ▶ Revier von Lebewesen Randon-Furling, Majumdar, Comtet (2009)
- ▶ Krankheitsausbreitung Dumonteil, Majumdar, Rosso, Zoia (2013)
- ▶ grundlegendes Interesse seit ~ 40 Jahren

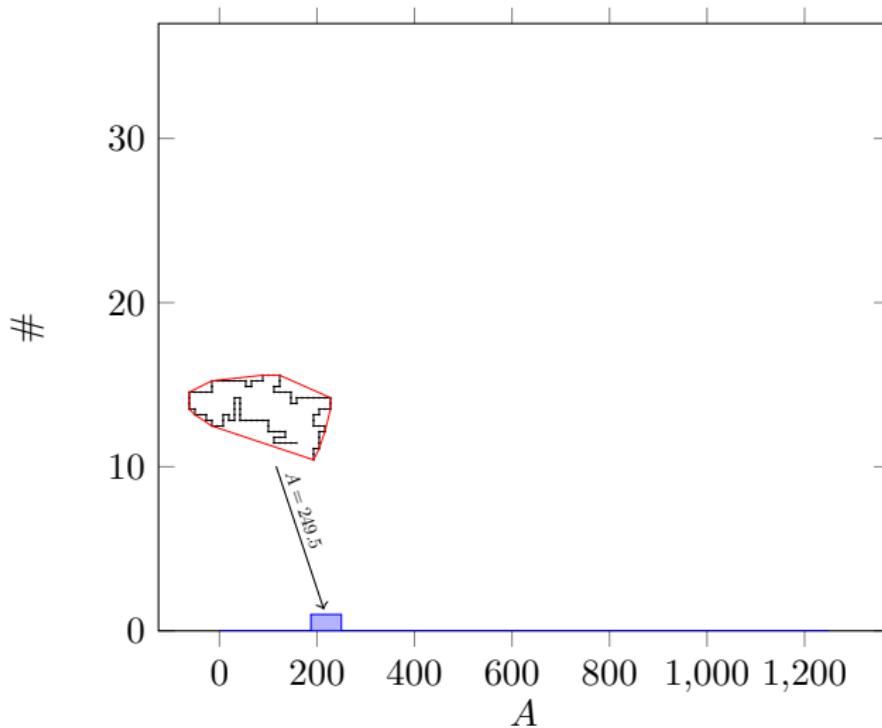


Letac, Takács (1980), Letac (1993), Goldman (1996), Majumdar, Comtet, Randon-Furling (2010),
Eldan (2014), Claussen, Hartmann, Majumdar (2015), Kabluchko, Zaporozhets (2016),
Schawe, Hartmann, Majumdar (2017), Schawe, Hartmann, Majumdar (2018)



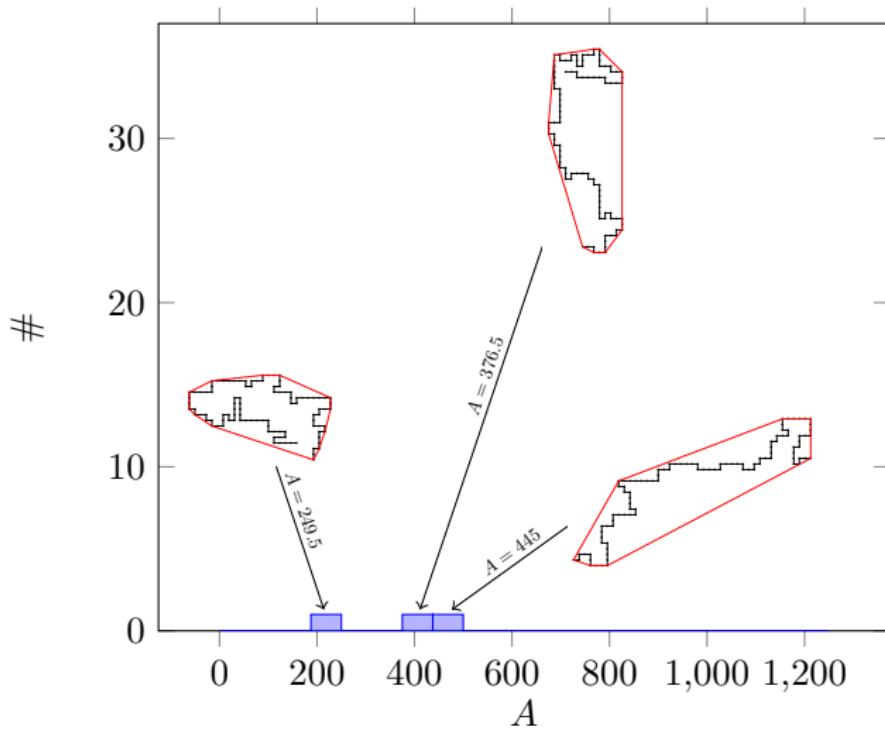
Verteilung der Fläche

$$T = 100$$



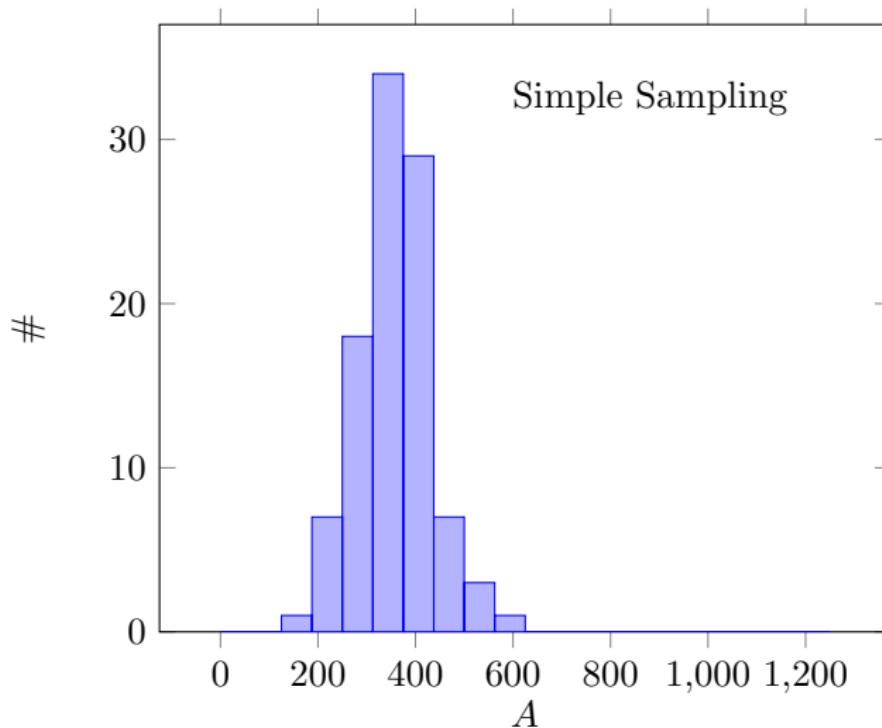
Verteilung der Fläche

$$T = 100$$



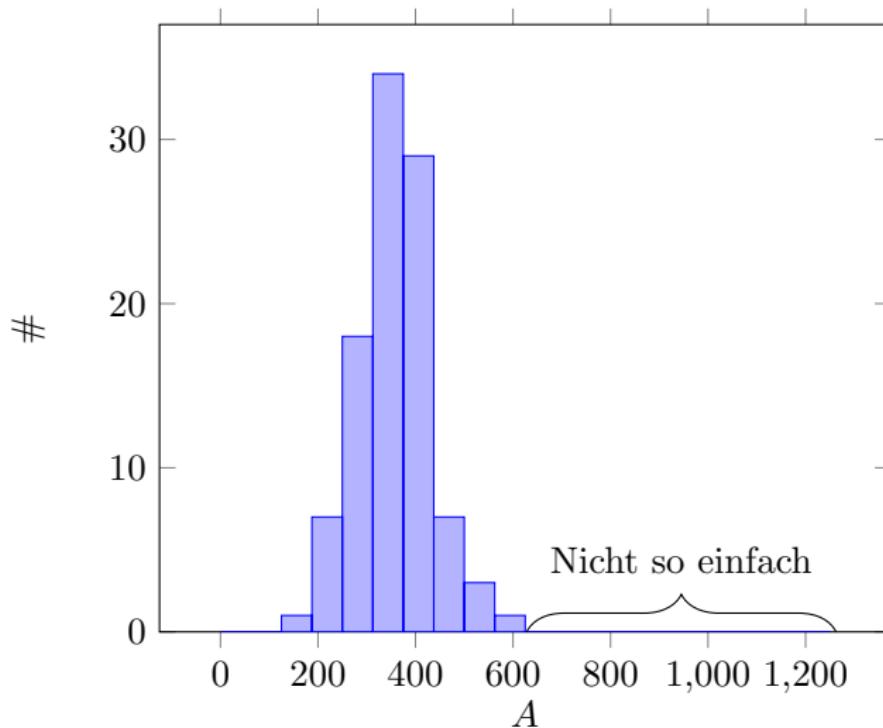
Verteilung der Fläche

$$T = 100$$



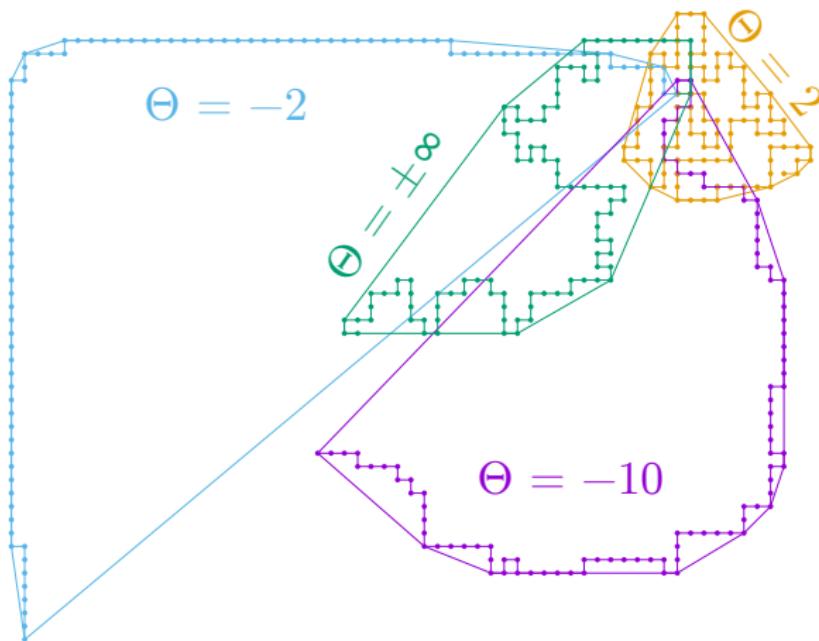
Verteilung der Fläche

$$T = 100$$



Large Deviation Simulation

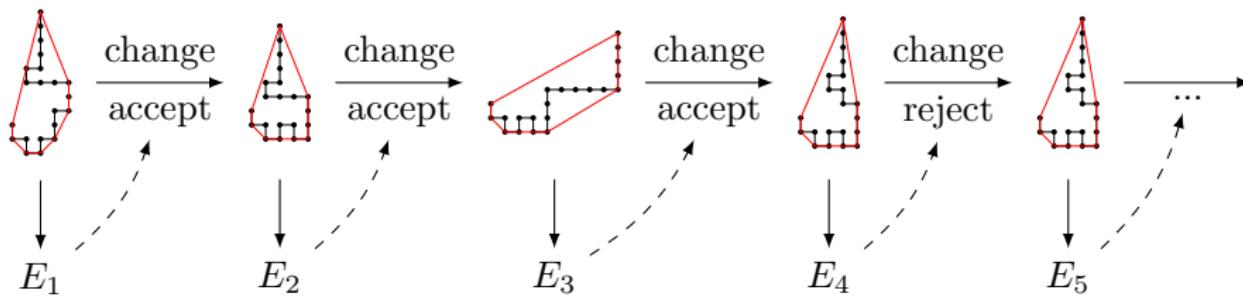
- Behandle Modell wie kanonisches System $\sim e^{-E/\Theta}$
- betrachte Fläche als Energie $A \equiv E$
- künstliche Temperatur Θ



Metropolis Algorithmus

- Markov Kette von Zuständen = Realisierung von RWs
- akzeptiere kleine Änderung mit Wahrscheinlichkeit

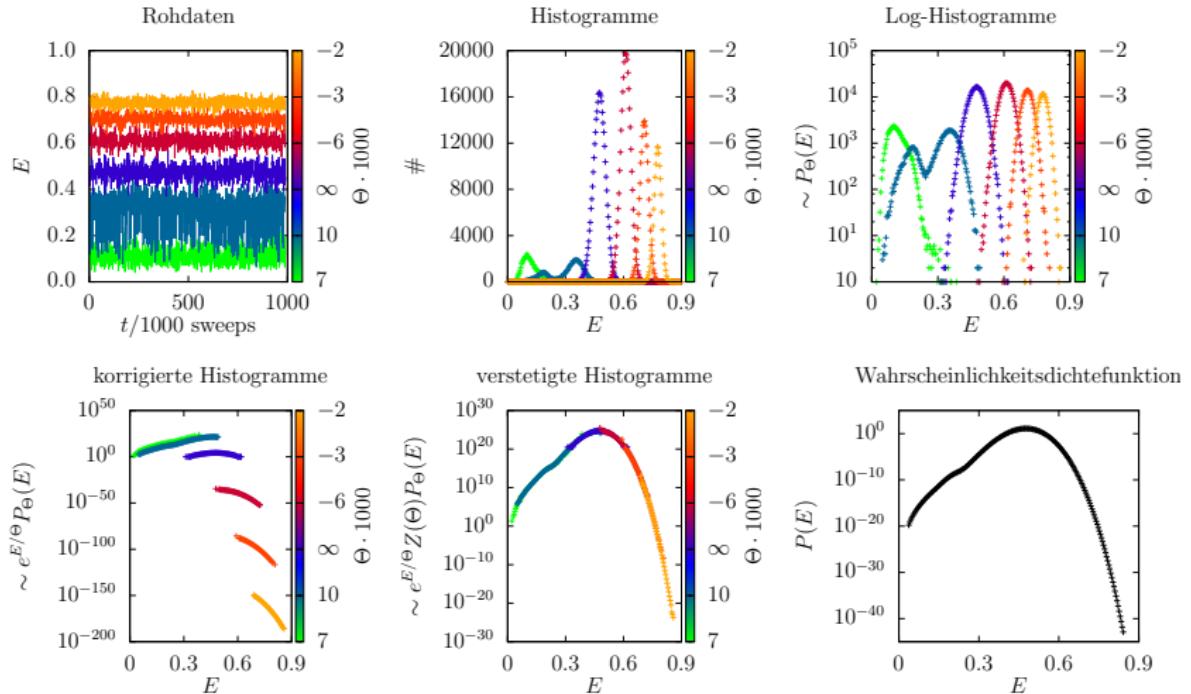
$$p_{\text{acc}} = \min \left\{ 1, e^{-\Delta E / \Theta} \right\}$$



Metropolis et al., 1954

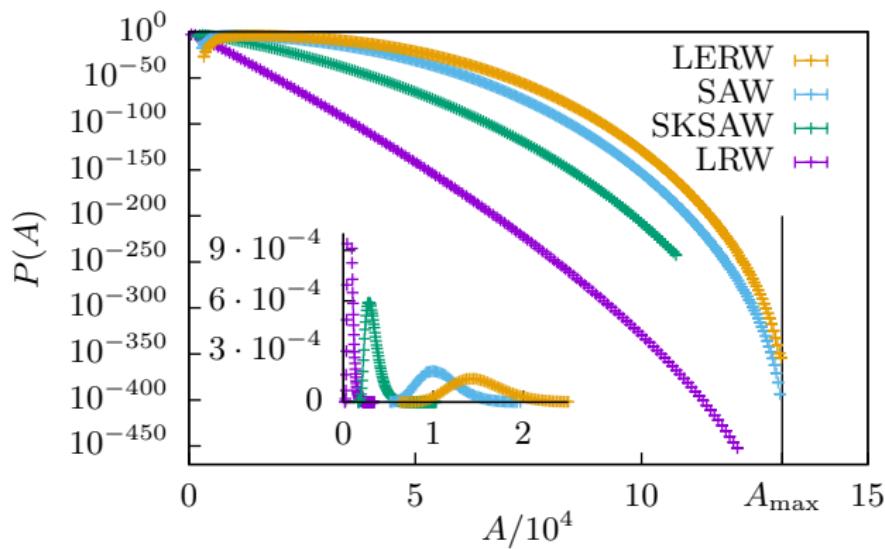


Large Deviation Simulation



Kovexe H\"ullen von Random Walks

Verteilungen \"uber alle m\"oglichen Werte

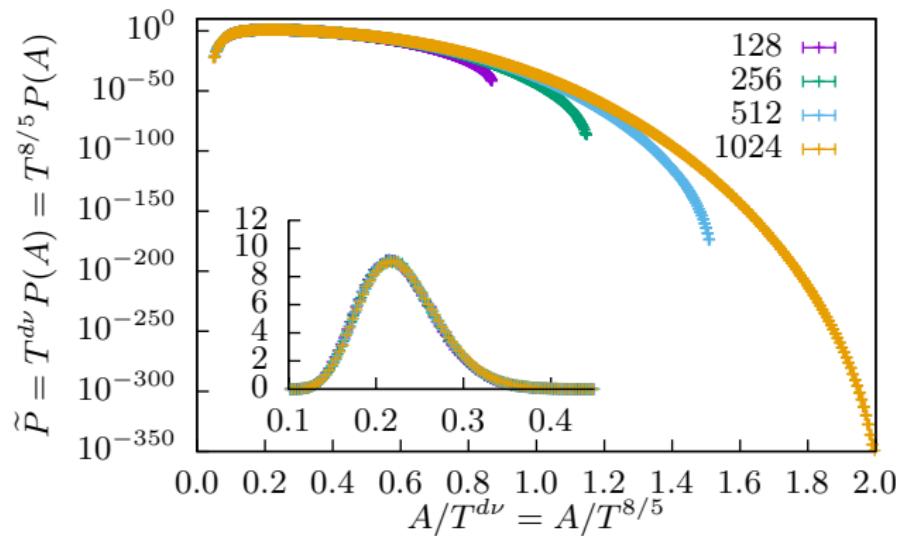


$$T = 1024$$



Kovexe H\"ullen von Random Walks

Mittelwerte skalieren wie $T^{d\nu}$. Verteilung auch?



LERW, $\nu = 4/5$, $d = 2$



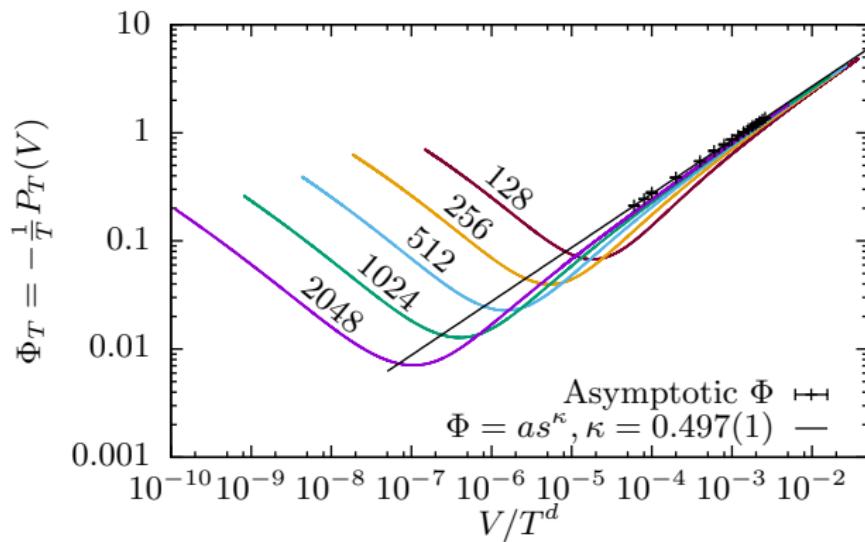
Exkurs: Large-Deviation-Theorie

Large-Deviation-Prinzip:

Für $T \rightarrow \infty$ ist die ganze Verteilung gegeben als Ratenfunktion:

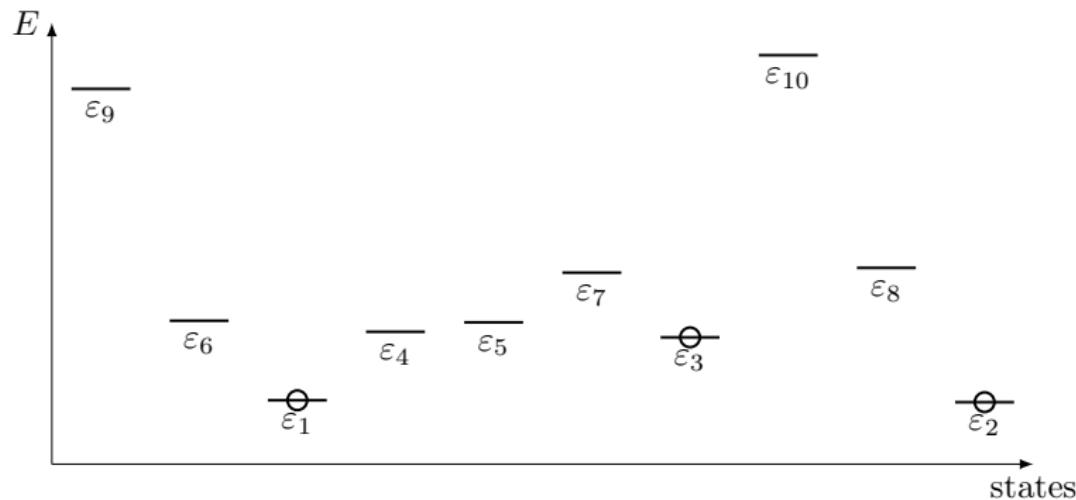
$$P_T(V) = e^{-T\Phi(V)+o(T)}$$

Ratenfunktion sollte wie $\Phi \propto V^\kappa$, $\kappa = \frac{1}{d(1-\nu)}$ gehen. Stimmt das?



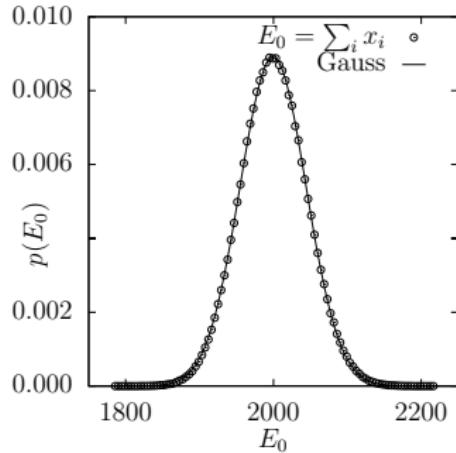
Grundzustandsverteilung eines Random-Energy-Modells

- ▶ N Energieniveaus ε_i , ($\varepsilon_1 \leq \varepsilon_2 \leq \dots \leq \varepsilon_N$)
- ▶ unabhängig, identisch aus Verteilung $p(\varepsilon)$, $\varepsilon \geq 0$
- ▶ K Fermionen
- ▶ Grundzustandsenergie $E_0 = \sum_{i=1}^K \varepsilon_i$
- ▶ ähnlich verallgemeinertem Spinglas-Modell Derrida (1980)

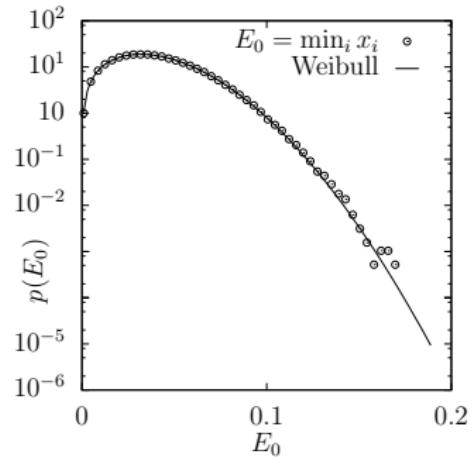


Extrema

$K = N$: Zentraler
Grenzwertsatz: Gauß



$K = 1$: Extremwerttheorie:
Weibull



Was ist die Verteilung für beliebige K ?



Ergebnis von G. Schehr und S. Majumdar

Ausgehend von

$$P(\varepsilon_1, \dots, \varepsilon_K) = \frac{\Gamma(N+1)}{\Gamma(N-K+1)} \prod_{i=1}^K p(\varepsilon_i) \prod_{i=2}^K \Theta(\varepsilon_i - \varepsilon_{i-1}) \left[\int_{\varepsilon_K}^{\infty} p(u) \, du \right]^{N-K}$$

wurde das Skalenverhalten für $N \rightarrow \infty$ hergeleitet

$$P_{K,N}(E_0) \approx b N^{\frac{1}{\alpha+1}} F_K^{(\alpha)} \left(b N^{\frac{1}{\alpha+1}} E_0 \right)$$

mit explizitem Ausdruck für

$$\int_0^{\infty} F_K^{(\alpha)}(z) e^{-\lambda z} \, dz = \frac{(\alpha+1)^K}{\Gamma(K) \lambda^{(\alpha+1)(K-1)}} \int_0^{\infty} x^{\alpha} e^{-\lambda x - x^{\alpha+1}} [\gamma(\alpha+1, \lambda x)]^{K-1} \, dx$$

Universell mit zwei Parametern

$$p(\varepsilon) \stackrel{\varepsilon \rightarrow 0}{\approx} B \varepsilon^{\alpha}$$

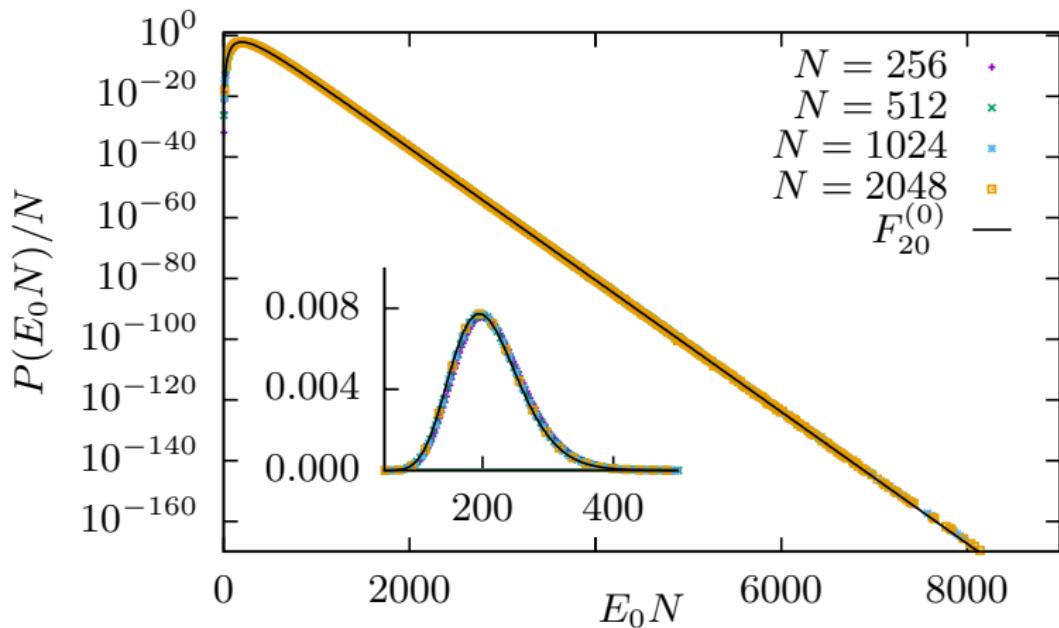
$$b = (B/(\alpha+1))^{1/(\alpha+1)}$$



Numerische Ergebnisse

Exponentialverteilte ε ($\alpha = 0, B = 1$), $K = 20$

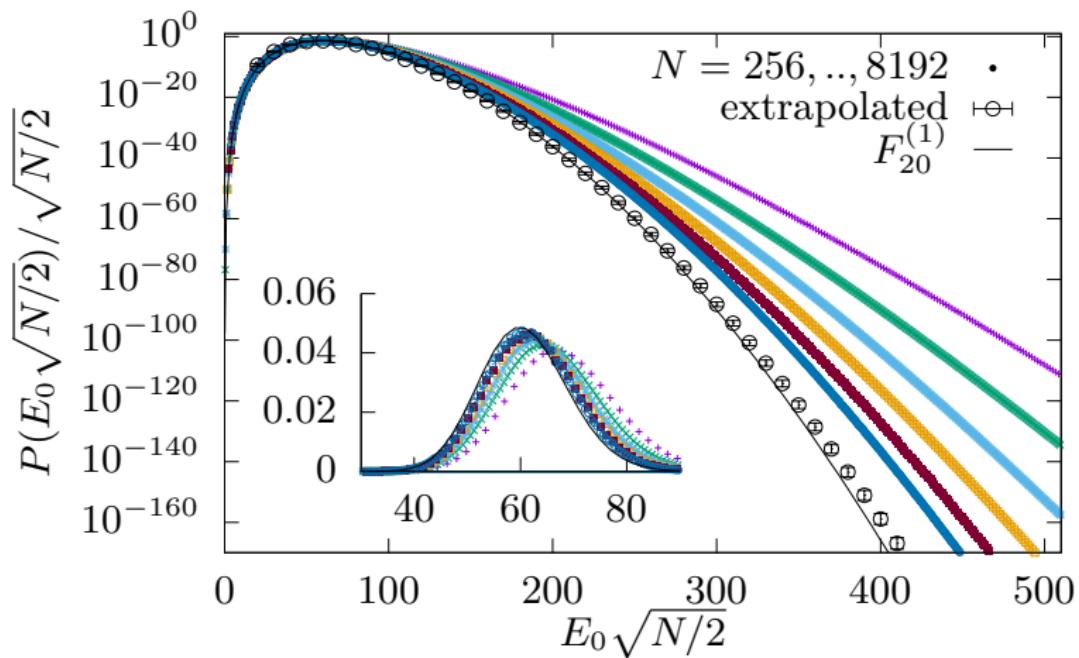
$$p(\varepsilon) = e^{-\varepsilon}, \varepsilon > 0$$



Numerische Ergebnisse

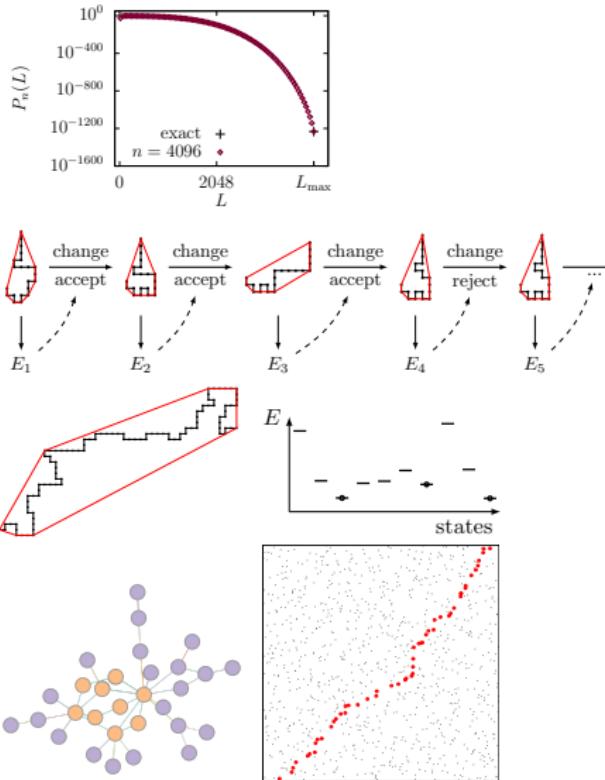
Erlangverteilte ε ($\alpha = 1, B = 1$), $K = 20$

$$p(\varepsilon) = \varepsilon e^{-\varepsilon}, \varepsilon > 0$$



Zusammenfassung

- ▶ Untersuchung von Verteilungen inklusive der Enden
- ▶ mittels Markov-Chain-Monte-Carlo
- ▶ für sehr unterschiedliche Modelle
- ▶ zur Untersuchung von Skalenverhalten
- ▶ und Ratenfunktionen

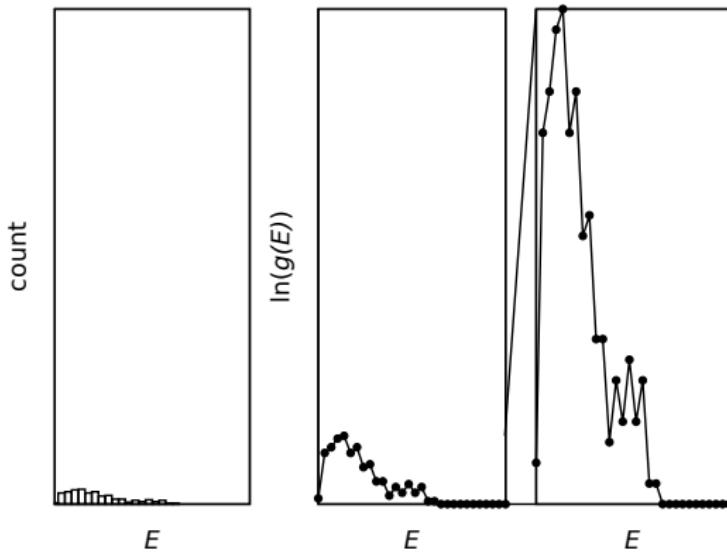


Wang-Landau

Ähnlich Metropolis, aber Akzeptanz mit

$$p_{\text{acc}}(c_i \rightarrow c') = \min \left\{ 1, \frac{g(E(c_i))}{g(E(c'))} \right\}$$

$g(E)$ wird während der Simulation angepasst.

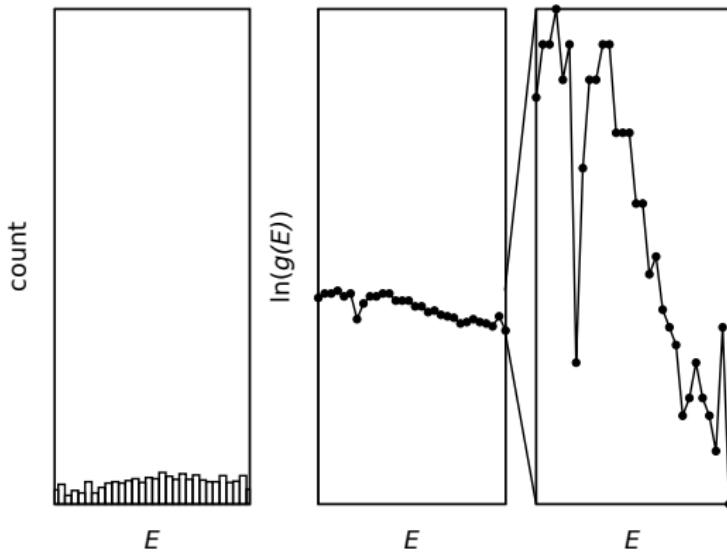


Wang-Landau

Ähnlich Metropolis, aber Akzeptanz mit

$$p_{\text{acc}}(c_i \rightarrow c') = \min \left\{ 1, \frac{g(E(c_i))}{g(E(c'))} \right\}$$

$g(E)$ wird während der Simulation angepasst.

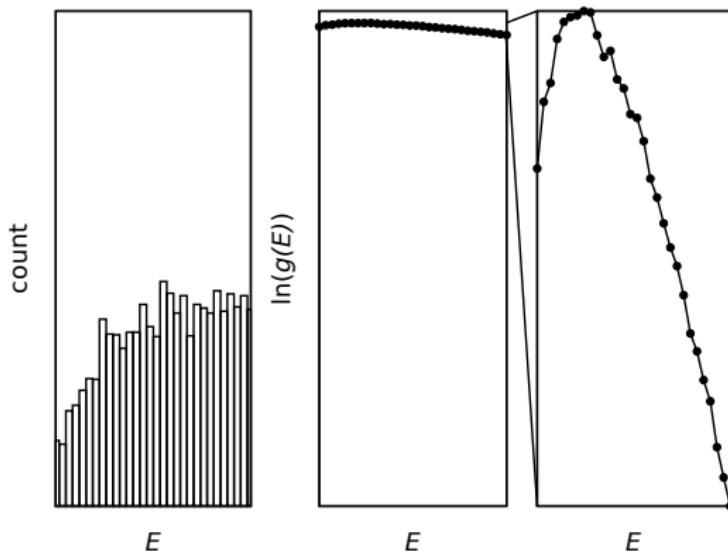


Wang-Landau

Ähnlich Metropolis, aber Akzeptanz mit

$$p_{\text{acc}}(c_i \rightarrow c') = \min \left\{ 1, \frac{g(E(c_i))}{g(E(c'))} \right\}$$

$g(E)$ wird während der Simulation angepasst.

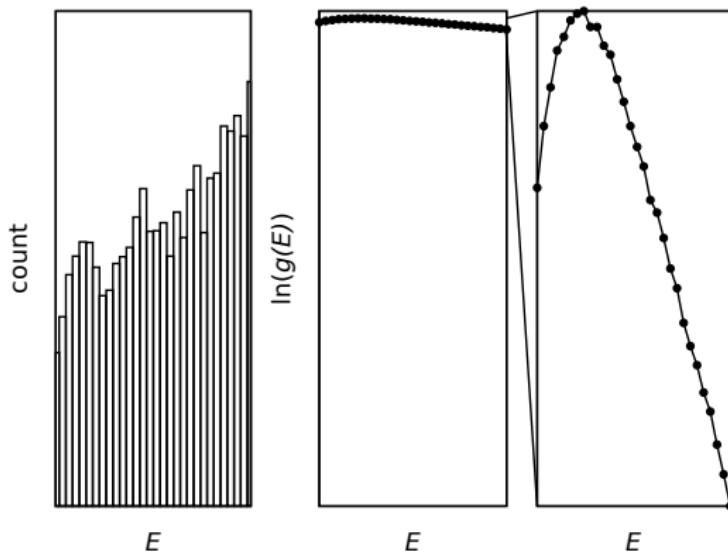


Wang-Landau

Ähnlich Metropolis, aber Akzeptanz mit

$$p_{\text{acc}}(c_i \rightarrow c') = \min \left\{ 1, \frac{g(E(c_i))}{g(E(c'))} \right\}$$

$g(E)$ wird während der Simulation angepasst.



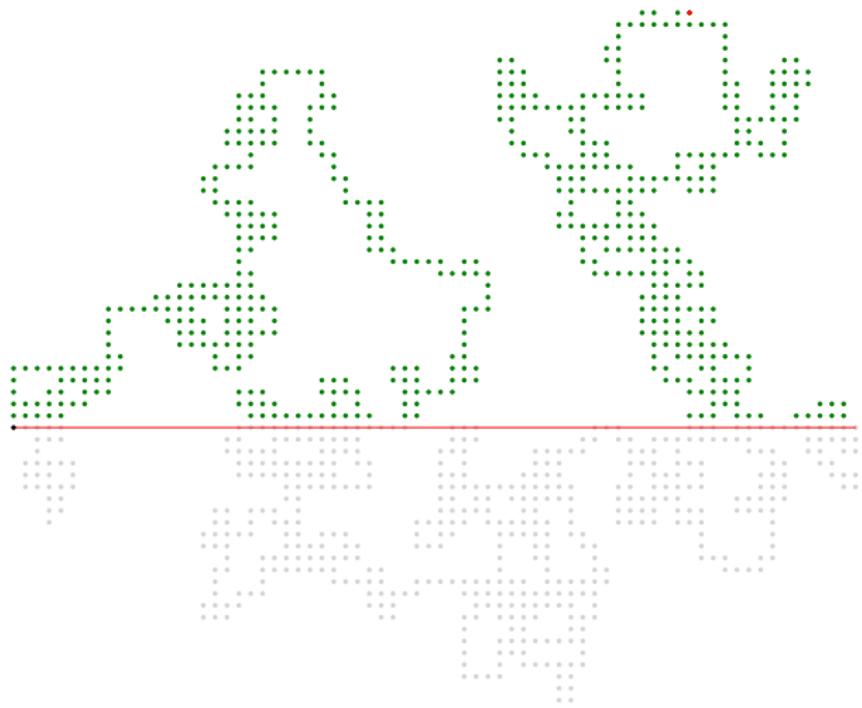
Quickhull



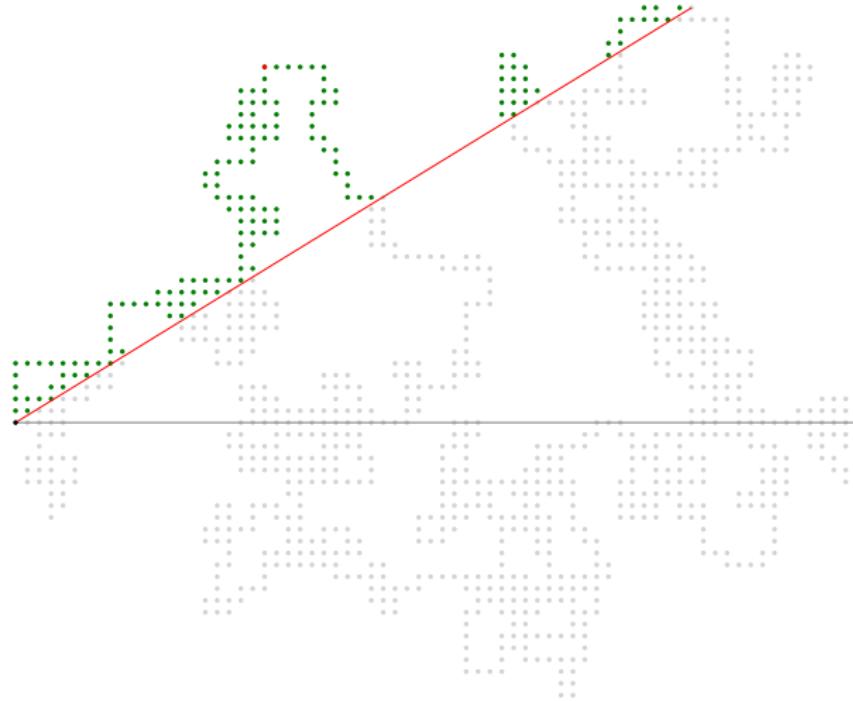
Quickhull



Quickhull



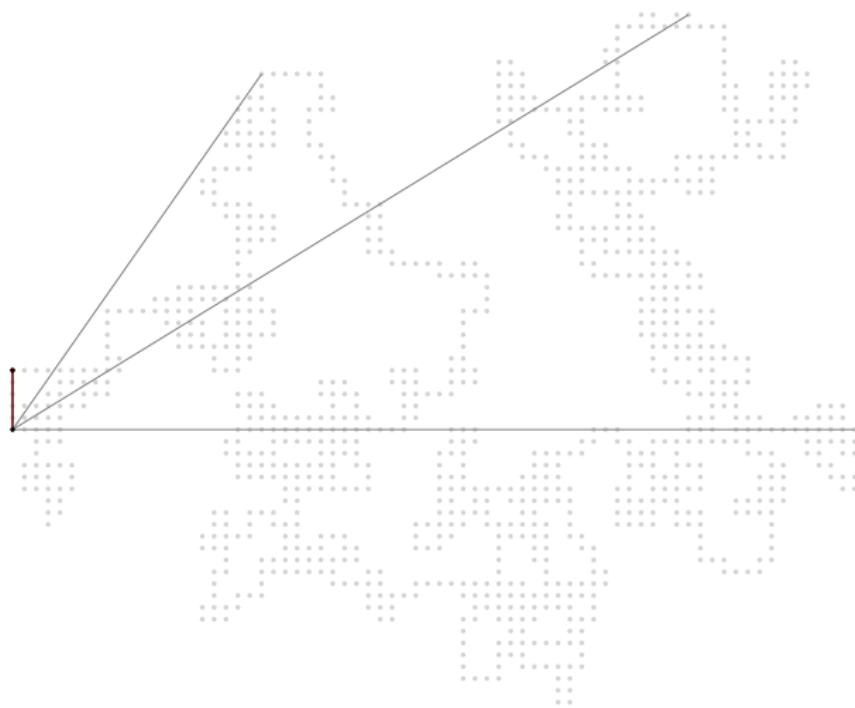
Quickhull



Quickhull



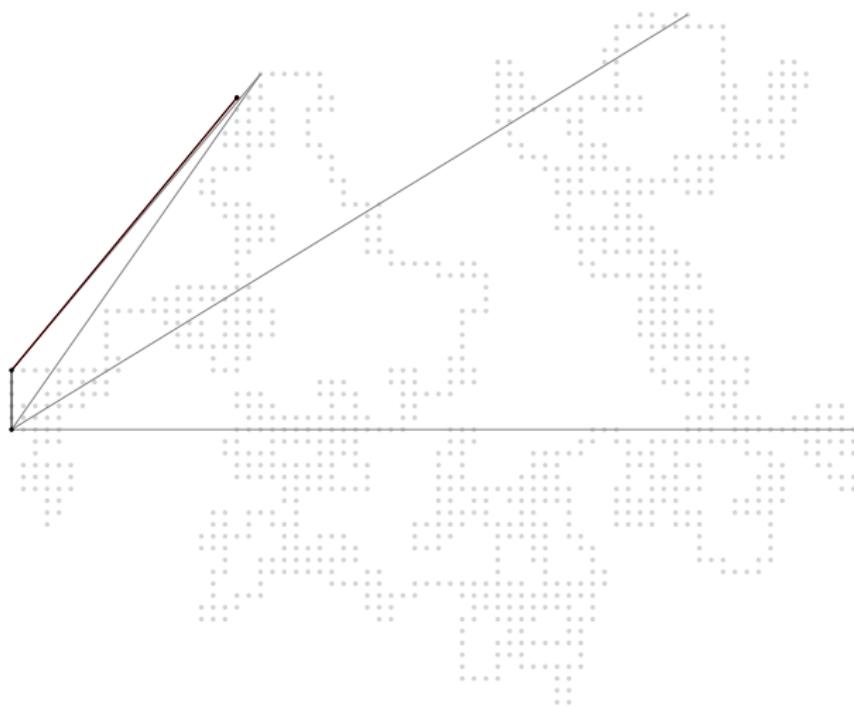
Quickhull



Quickhull



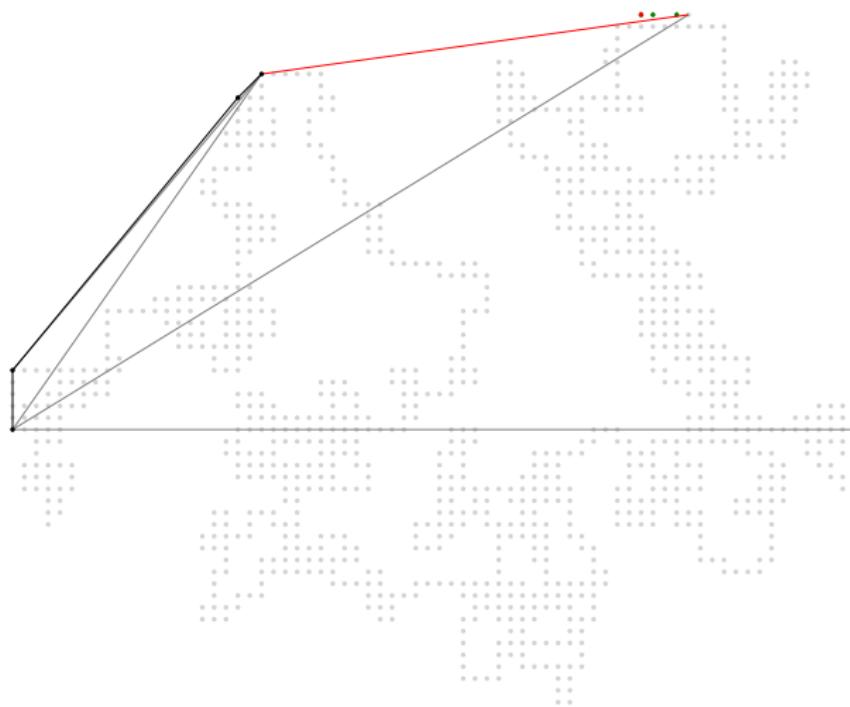
Quickhull



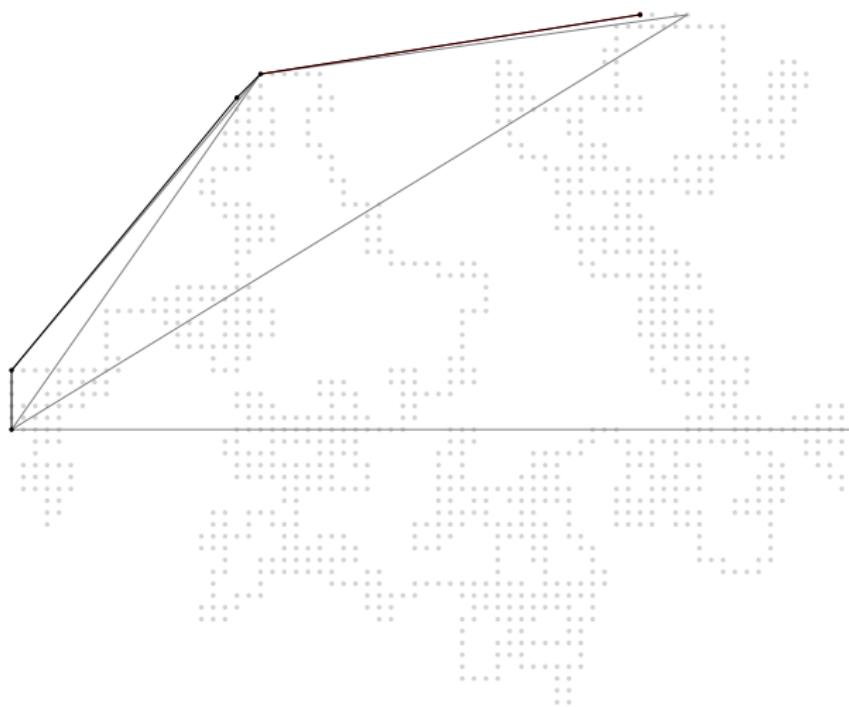
Quickhull



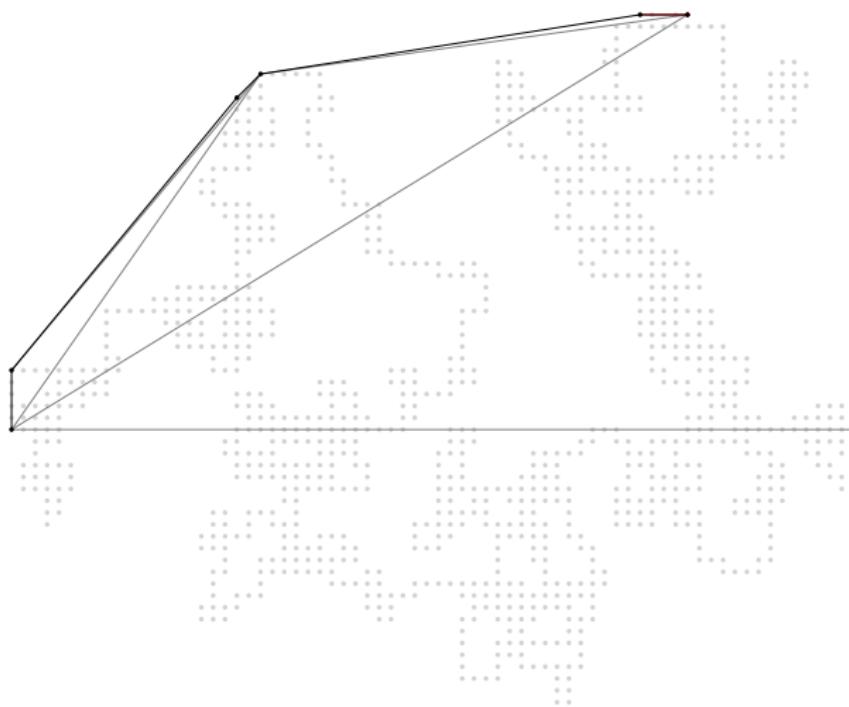
Quickhull



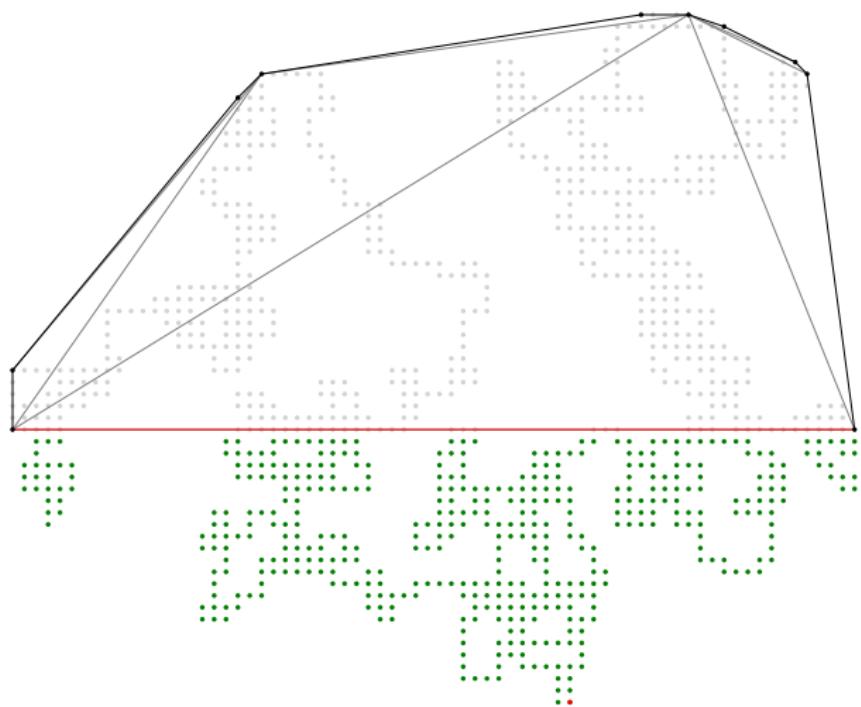
Quickhull



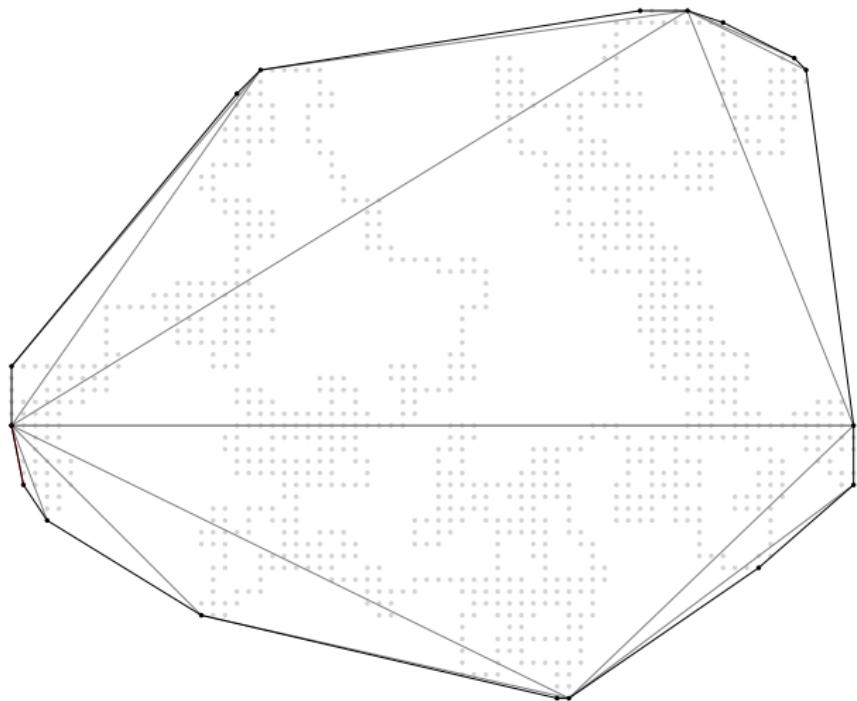
Quickhull



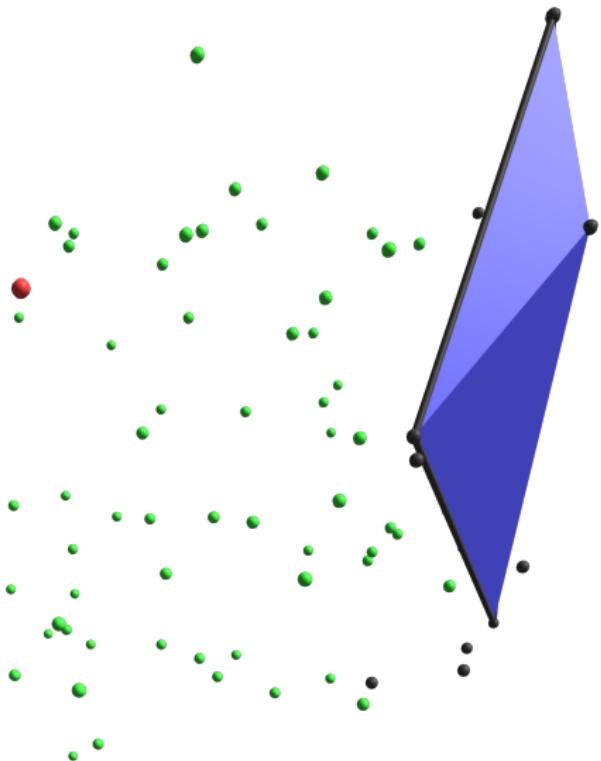
Quickhull



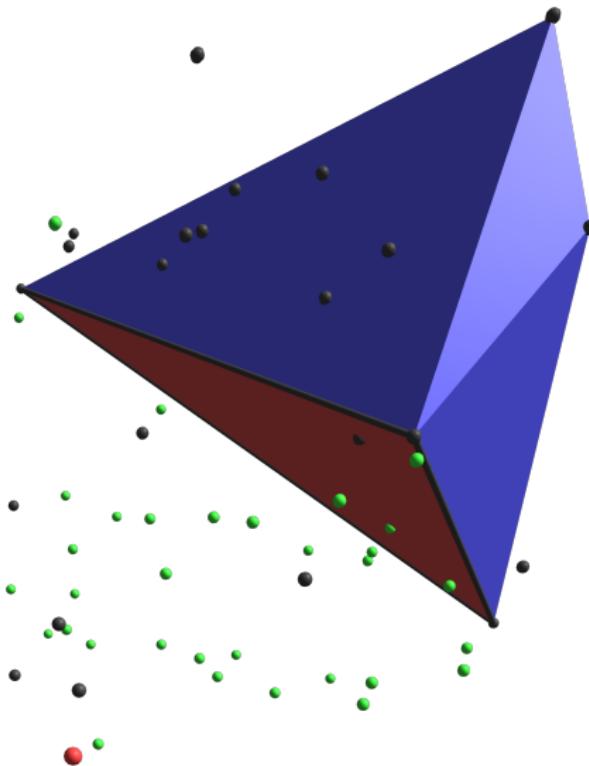
Quickhull



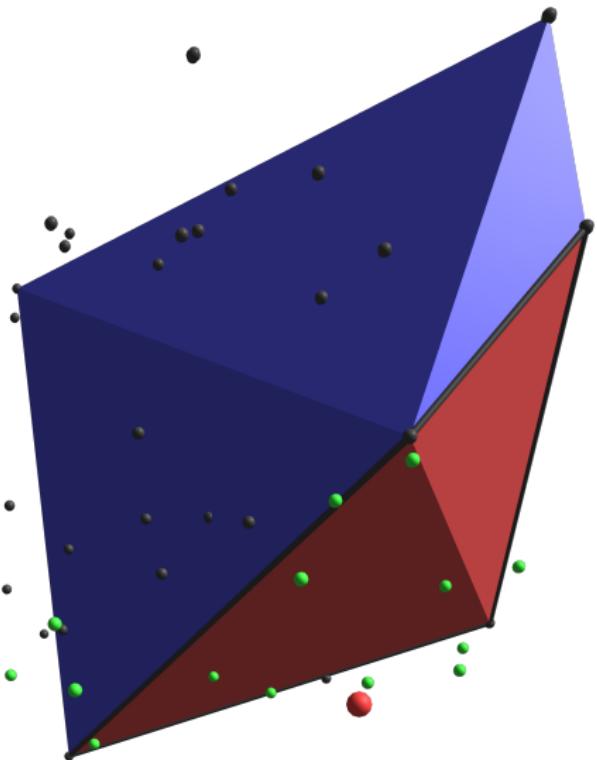
Quickhull



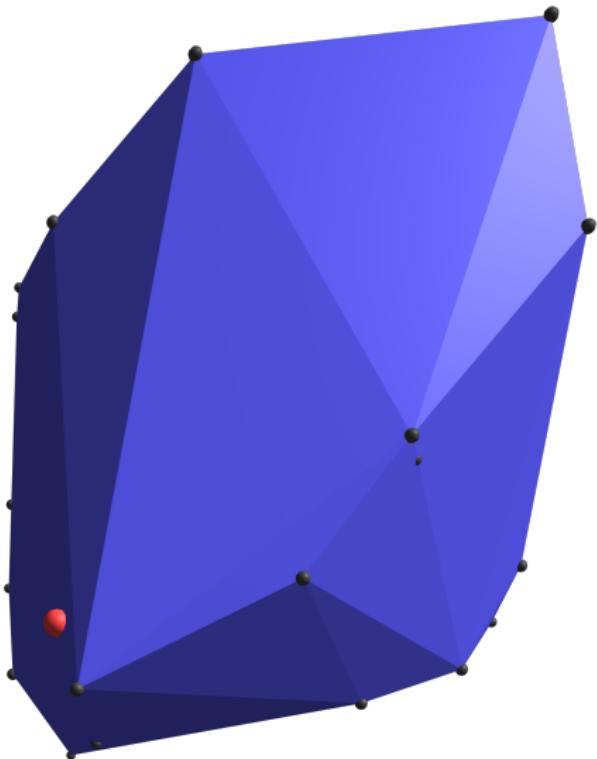
Quickhull



Quickhull

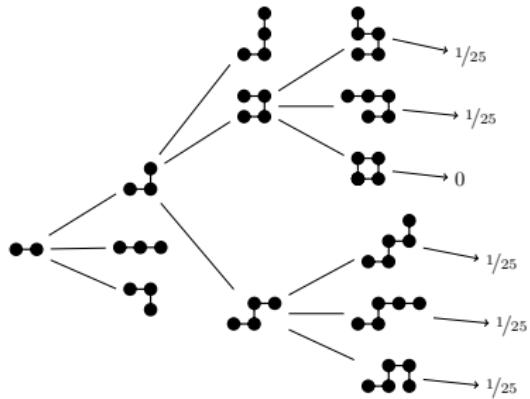


Quickhull

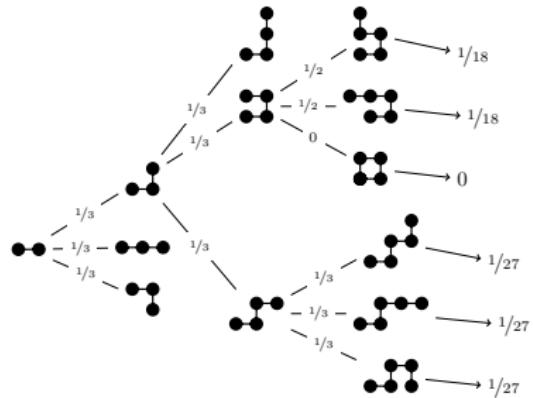


SAW vs. SKSAW

SAW



SKSAW



Warum sollte die Ratenfunktion so aussehen?

LDP: $P_T = \exp(-T\Phi(S/T^d))$

Ansatz: $\Phi \propto V^\kappa$

Annahme: Skalenform $P_T(V) = T^{-d\nu} \tilde{P}(S/T^{d\nu})$ existiert

Argument: Wenn lhs $f(S/T^{d\nu})$, dann rhs auch $f(S/T^{d\nu})$

$$\begin{aligned} T^{-d\nu} \tilde{P}(ST^{-d\nu}) &\approx \exp(-T\Phi(S/T^d)) \\ &\propto \exp(-T(S/T^d)^\kappa) \\ &= \exp(-T^{d\kappa - \nu d\kappa} (S/T^d)^\kappa) \\ &= \exp(-T^{-\nu d\kappa} S^\kappa) \\ &= \exp(-(S/T^{\nu d})^\kappa) \end{aligned}$$

Funktioniert nur mit:

$$1 = d\kappa - \nu d\kappa \Rightarrow \kappa = \frac{1}{d(1 - \nu)}$$

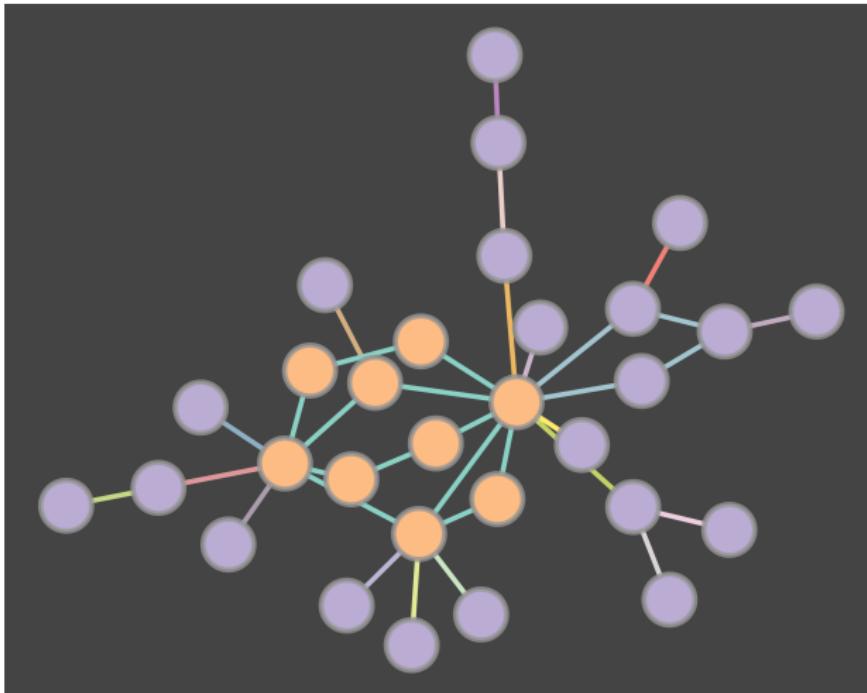


REM

$$P_{K,N}(E_0) = \int P(\varepsilon_1, \dots, \varepsilon_K) \delta\left(E_0 - \sum_{i=1}^K \varepsilon_i\right) \prod_{i=1}^K d\varepsilon_i$$

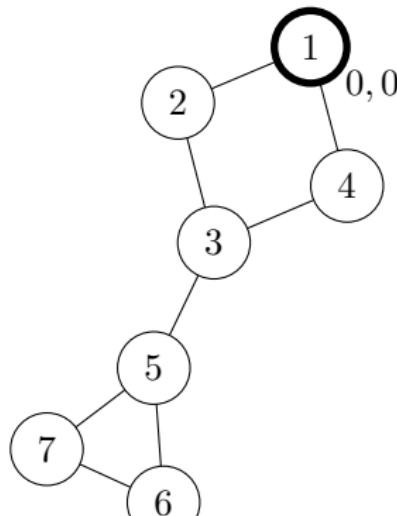
Laplacetransformation, Vereinfachungen und große N -Näherungen, und geeignete Skalierung führen auf N -unabhängige Form: F_K , deren Laplacetransformation bekannt ist.

Zweifachzusammenhangskomponenten



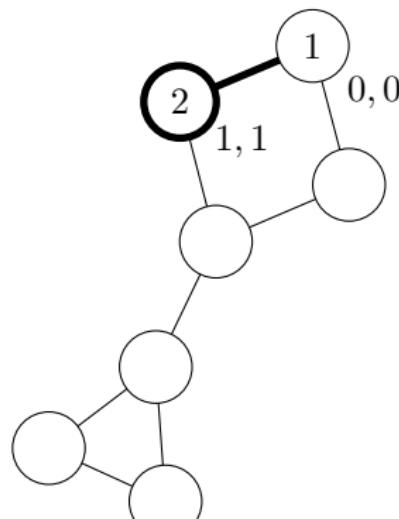
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind

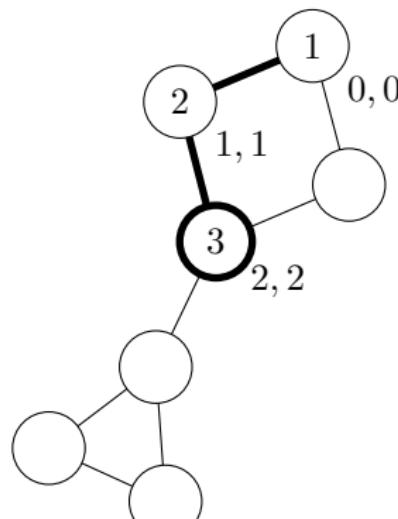


1	2					
---	---	--	--	--	--	--



Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind

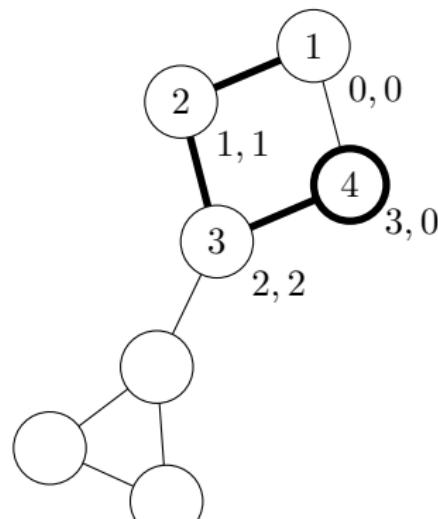


1	2	3				
---	---	---	--	--	--	--



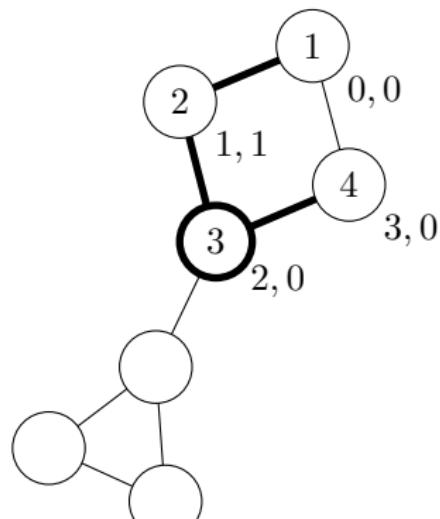
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind

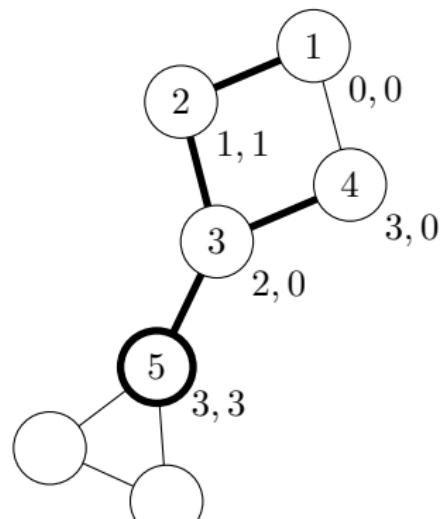


1	2	3				
---	---	---	--	--	--	--



Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind

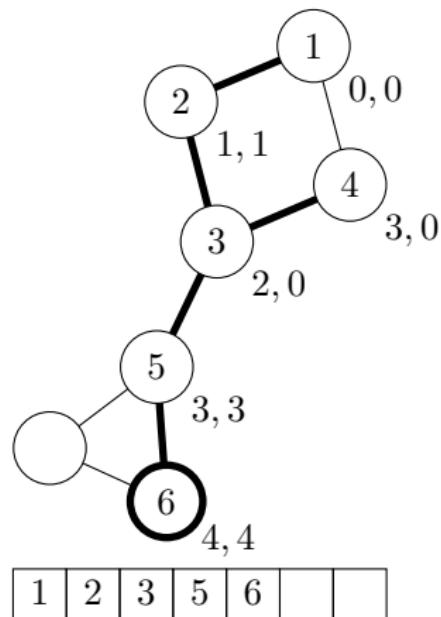


1	2	3	5			
---	---	---	---	--	--	--



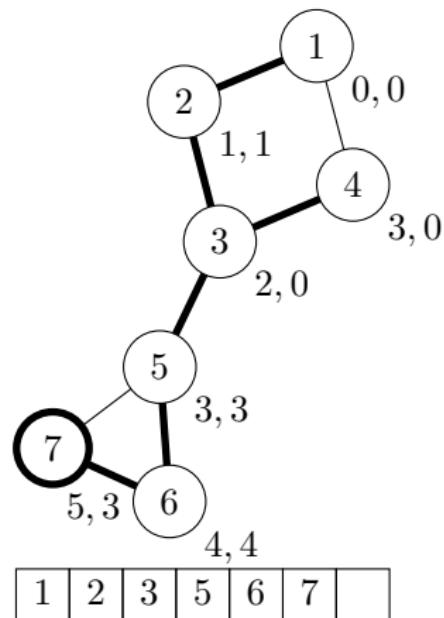
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



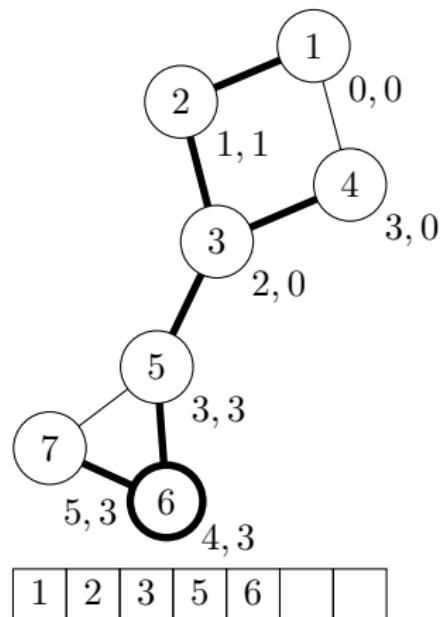
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



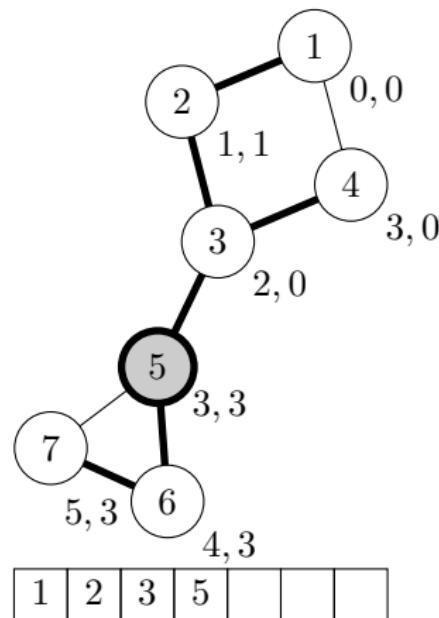
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



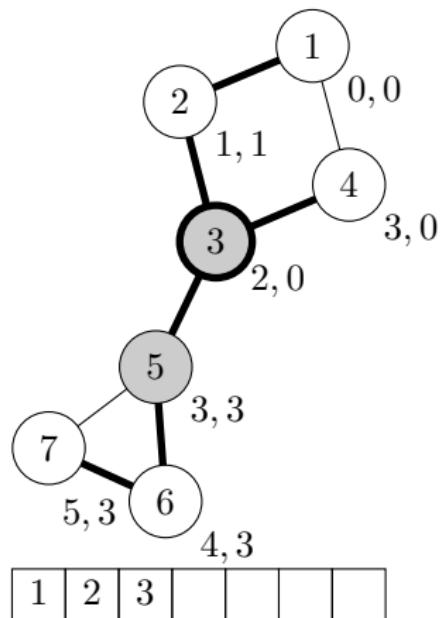
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



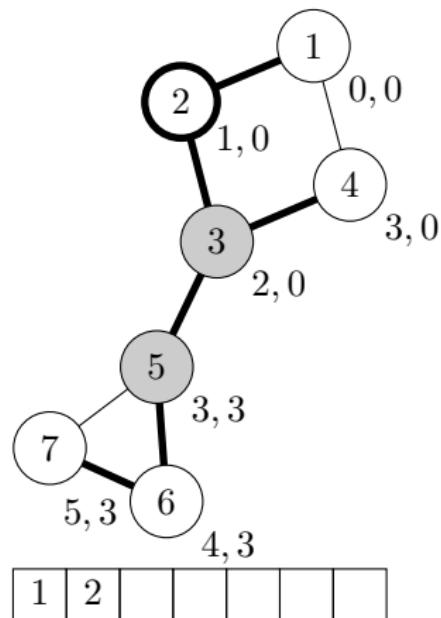
Algorithmus zur Komponentenfindung

Artikulationspunkt wenn $depth \leq lowpoint$ von Kind

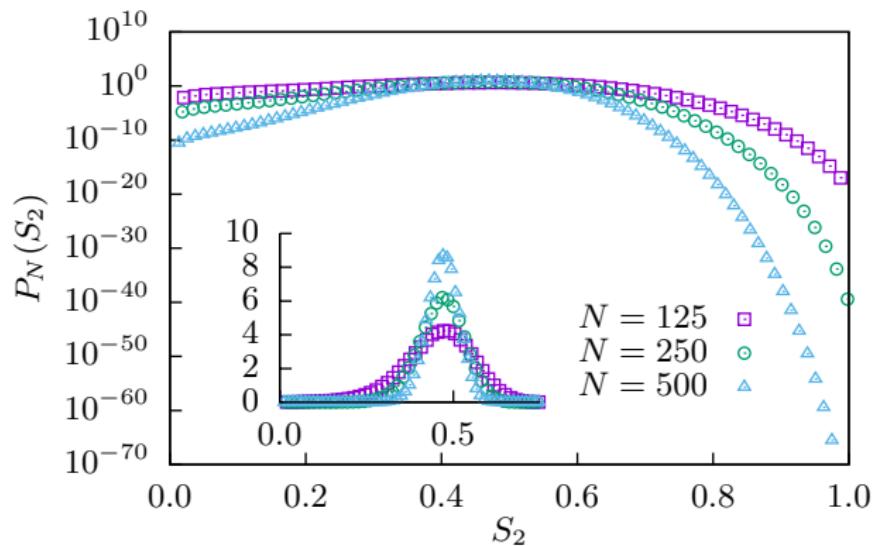


Algorithmus zur Komponentenfindung

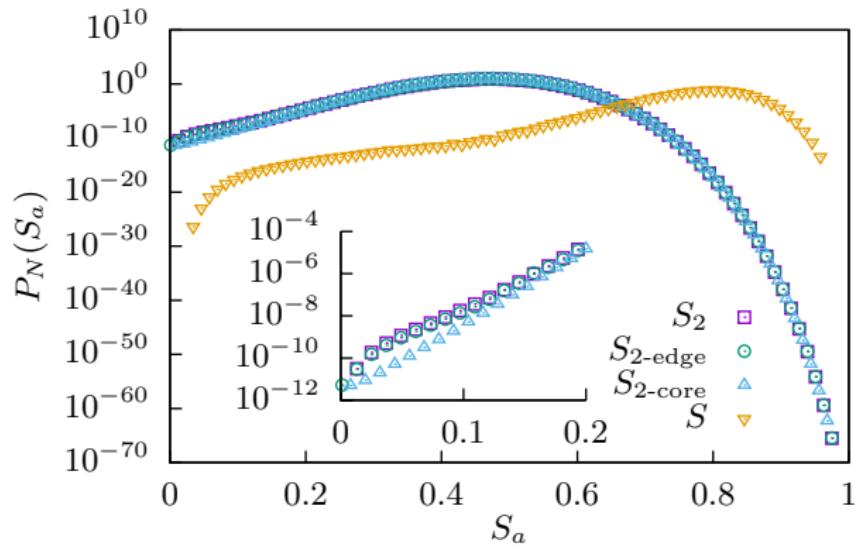
Artikulationspunkt wenn $depth \leq lowpoint$ von Kind



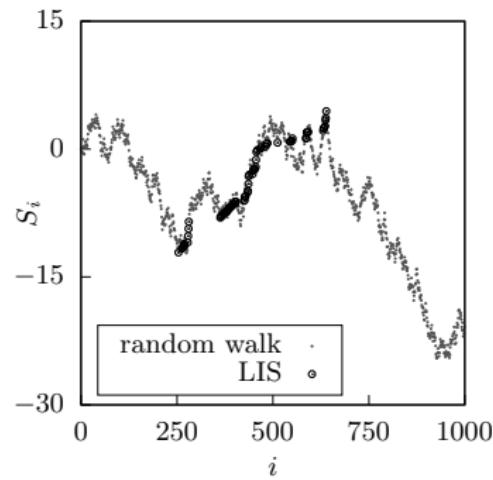
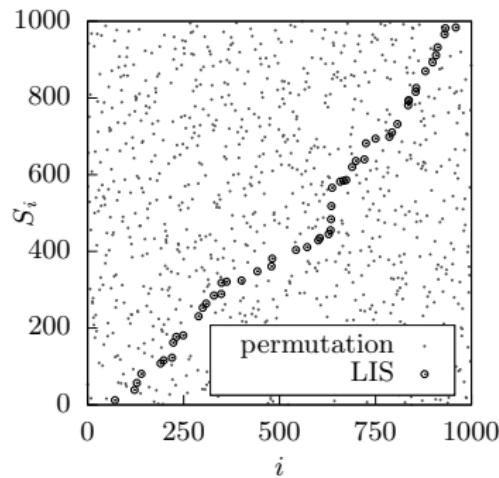
Verteilung Zweifachzusammenhangskomponentengröße



Verteilung verschiedene Komponenten



Längste aufsteigende Teilfolge



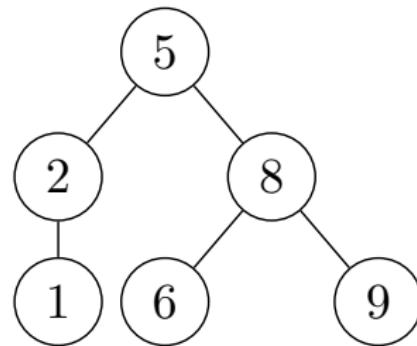
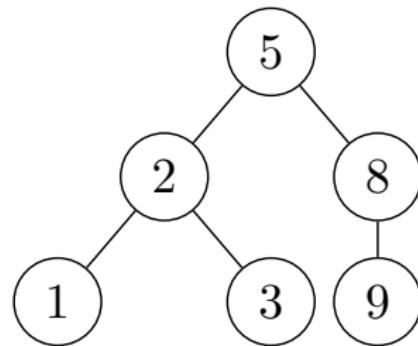
$$S = (\underline{3}, 9, \underline{4}, \overline{1}, \overline{2}, \underline{7}, \overline{6}, \overline{8}, 0, 5)$$



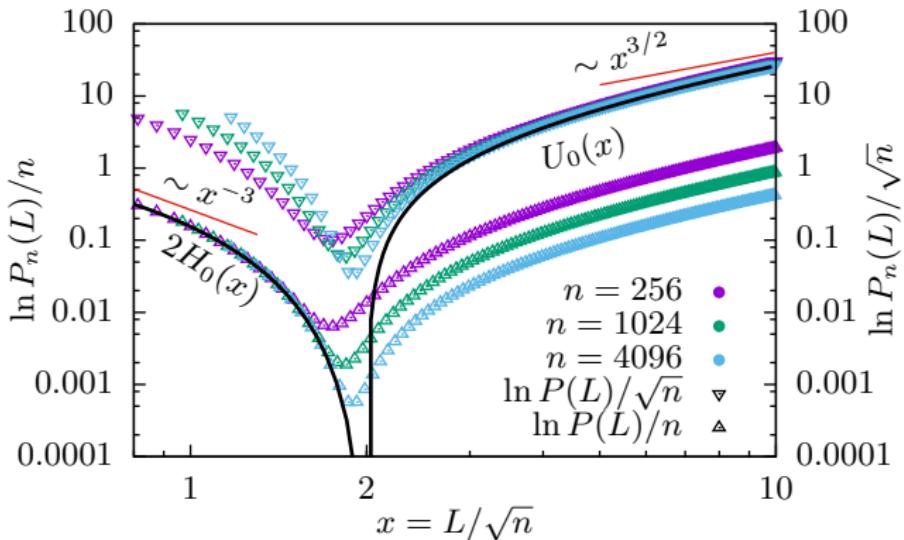
Datenstruktur für effiziente MCMC changes

9	2	5	3	8	1
---	---	---	---	---	---

9	2	5	6	8	1
---	---	---	---	---	---



Ratenfunktionen, Zufallspermutation



Skalenverhalten, Random Walk

